

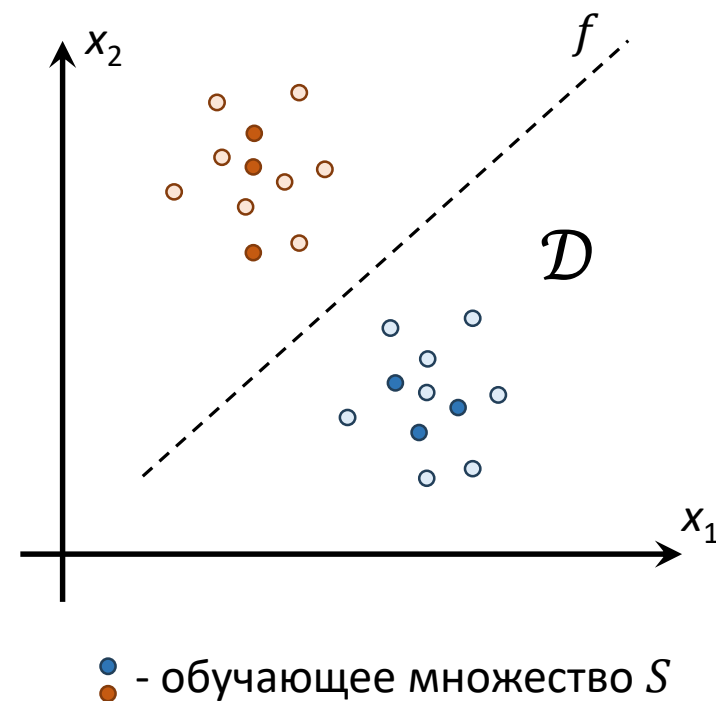
Методы искусственного интеллекта

Лекция 4. Обучение. Нейронные сети

Тема 9. Основы обучения с учителем

Постановка задачи обучения с учителем

- Исходные данные:
 - Множество примеров (образцов) \mathcal{X} , представленные как векторы *признаков*.
 - Пространство меток \mathcal{Y} :
 - Например, у бинарной классификации $\mathcal{Y} = \{0, 1\}$.
 - Обучающее множество $S = ((x_1, y_1), \dots, (x_m, y_m))$ - конечное подмножество $\mathcal{X} \times \mathcal{Y}$
 - Образцы распределены в соответствии с некоторым распределением $\mathcal{X} \sim \mathcal{D}$
 - Есть (неизвестная) функция $f: \mathcal{X} \rightarrow \mathcal{Y}$, $y_i = f(x_i), \forall i$.

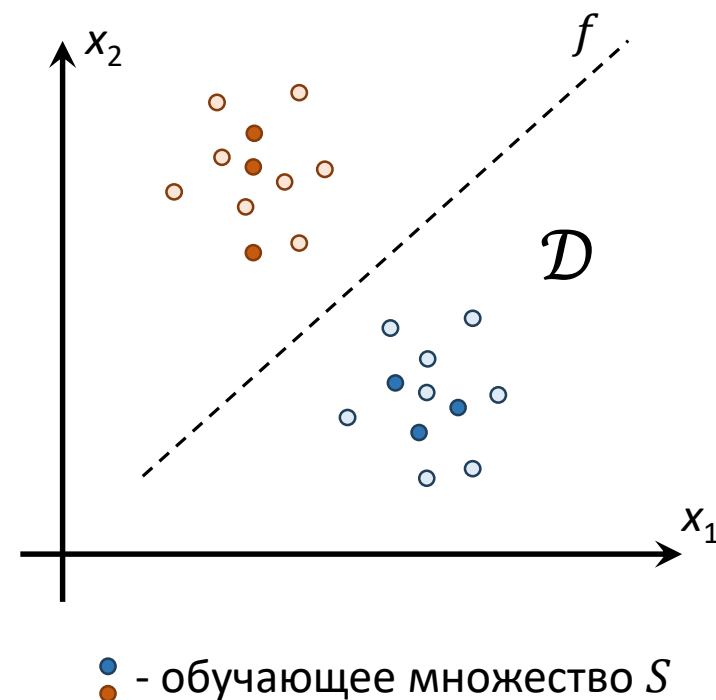


Постановка задачи обучения с учителем

- Выходные данные алгоритма обучения:
 - Модель (гипотеза, решающее правило) $h \in \mathcal{H}$, где \mathcal{H} - пространство гипотез.
- Мера успеха (для классификации):
 - Вероятность того, что объект, извлеченный из распределения \mathcal{D} , будет неверно классифицирован моделью h :


$$L_{\mathcal{D},f}(h) \stackrel{\text{def}}{=} \mathbb{P}_{x \sim \mathcal{D}}[h(x) \neq f(x)]$$

- Обучающий алгоритм не знает \mathcal{D} и f .




Виды моделей (гипотез)


Пространство гипотез,
задаваемое тремя делениями
пространства признаков
(деревья решений)



Пространство гипотез,
задаваемое прямой линией




Пространство гипотез,
задаваемое параболой,
разграничивающей области с
разным значением целевой
переменной




Виды моделей (гипотез). Параметрические модели

Пространство гипотез,
задаваемое тремя делениями
пространства признаков
(дерево решений)




Пространство гипотез,
задаваемое прямой линией



$$y = \theta_1 x + \theta_2$$

Пространство гипотез,
задаваемое параболой,
разграничивающей области с
разным значением целевой
переменной



$$y = \text{sign}[\theta_1 x_1^2 + \theta_2 x_2^2 + \theta_3 x_1 x_2 + \theta_4 x_1 + \theta_5 x_2 + \theta_6]$$

Виды моделей (гипотез). Параметрические модели

$$y = h(x; \theta)$$

θ – вектор параметров модели.

Примеры конкретных моделей:

- $y = 3x + 5$
 - модель из пространства $\theta_1 x + \theta_2$ при $\theta = (3, 5)$
- $y = 3 \sin(2x) + 17$
 - модель из пространства $\theta_1 \sin(\theta_2 x + \theta_3) + \theta_4$ при $\theta = (3, 2, 0, 17)$

Минимизация эмпирического риска и функция потерь

- Поскольку \mathcal{D} и f неизвестны, то $L_{\mathcal{D},f}(h)$ оценить невозможно, поэтому истинная функция ошибок заменяется **эмпирической функцией ошибки** (для классификации):

$$L_S(h) \stackrel{\text{def}}{=} \frac{|\{i \in [m] : h(x_i) \neq y_i\}|}{m}, \text{ где } [m] = \{1, \dots, m\}$$

Функции потерь

- Функция потерь характеризует качество гипотезы (модели) на обучающем множестве.
- Является обобщением понятия эмпирического риска (в зависимости от класса задачи обучения)

Функции потерь

- Задача регрессии - среднеквадратичная ошибка


$$L_{MSD}(\hat{y}, y) = \frac{1}{m} \sum_{i=1}^m (\hat{y} - y)^2$$

- Задача бинарной классификации - бинарная энтропия:


$$L_{BCE}(\hat{y}, y) = -\frac{1}{m} \sum_{i=1}^m (y \log \hat{y} + (1 - y) \log (1 - \hat{y}))$$

Мощность (выразительность) гипотез


$$y = \theta$$



$$y = \theta_1 x + \theta_2$$



$$y = \theta_1 x^2 + \theta_2 x + \theta_3$$



Решение задачи. Оптимизация в пространстве параметров гипотезы

- За исключением простейших случаев (константа, линейный тренд и ряда других) о поиск глобального минимума функции потерь невозможен
- Решение: итеративные процедуры, основанные на градиентном спуске:


$$\hat{\theta}_i = \hat{\theta}_{i-1} - \alpha \frac{\partial L_S(h)}{\partial \theta}$$

Пример 1. Задача линейной регрессии

- Дано: набор данных S , включающий значения одной (независимой) переменной X и соответствующие им значения другой переменной Y
- Класс гипотез:
 - Линейные функции вида $y = \theta_1 x + \theta_2$
 - Два параметра: θ_1, θ_2
- Функция потерь:
 - MSE: $L = \frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2$

$S =$

x	y
2	4
3	8
4	10
4.5	10
5	10
6	13
7	16



Пример 1. Задача линейной регрессии


- Градиент функции потерь по параметрам θ_1, θ_2 :

$$\begin{aligned}\frac{\partial L_S(h)}{\partial \theta_1} &= \frac{\partial}{\partial \theta_1} \left(\frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 \right) = \\ &= \frac{\partial}{\partial \theta_1} \left(\frac{1}{m} \sum_{i=1}^m ((\theta_1 x + \theta_2) - y_i)^2 \right) = \\ &= \frac{1}{m} \left(\sum_{i=1}^m 2x((\theta_1 x + \theta_2) - y_i) \right) = \frac{2}{m} \left(\sum_{i=1}^m x \epsilon_i \right)\end{aligned}$$

$$\begin{aligned}\frac{\partial L_S(h)}{\partial \theta_2} &= \frac{\partial}{\partial \theta_2} \left(\frac{1}{m} \sum_{i=1}^m (\hat{y}_i - y_i)^2 \right) = \\ &= \frac{\partial}{\partial \theta_2} \left(\frac{1}{m} \sum_{i=1}^m ((\theta_1 x + \theta_2) - y_i)^2 \right) = \\ &= \frac{1}{m} \left(\sum_{i=1}^m 2((\theta_1 x + \theta_2) - y_i) \right) = \frac{2}{m} \left(\sum_{i=1}^m \epsilon_i \right)\end{aligned}$$

S =

x	y
2	4
3	8
4	10
4.5	10
5	10
6	13
7	16



Пример 1. Задача линейной регрессии

Начальные значения:

$$\theta_1 = 1.7$$

$$\theta_2 = 0.0$$


$$\frac{\partial L_S(h)}{\partial \theta} = \begin{pmatrix} \frac{\partial L_S(h)}{\partial \theta_1} \\ \frac{\partial L_S(h)}{\partial \theta_2} \end{pmatrix} = \begin{pmatrix} \frac{2}{m} \left(\sum_{i=1}^m x \epsilon_i \right) \\ \frac{2}{m} \left(\sum_{i=1}^m \epsilon_i \right) \end{pmatrix}$$

S =

x	y
2	4
3	8
4	10
4.5	10
5	10
6	13
7	16

$\hat{y}_i = \theta_1 x + \theta_2$	$\epsilon_i = \hat{y}_i - y_i$	$x \epsilon_i$
3.4	-0.6	-1.2
5.1	-2.9	-8.7
6.8	-3.2	-12.8
7.65	-2.35	-10.575
8.5	-1.5	-7.5
10.2	-2.8	-16.8
11.9	-4.1	-28.7


$$\frac{\partial L_S(h)}{\partial \theta} = \begin{pmatrix} -24.65 \\ -4.99 \end{pmatrix}$$




Линейная регрессия

$$y = 1.7x + 0$$

Loss = 7.35




$$\frac{\partial L}{\partial \theta} = (-24.65, -4.99)$$




Линейная регрессия

$$y = 1.94x + 0.05$$

$$\text{Loss} = 2.518$$




$$\frac{\partial L}{\partial \theta} = (-13, -2.67)$$




Линейная регрессия

$$y = 2.08x + 0.08$$

$$\text{Loss} = 1.176$$




$$\frac{\partial L}{\partial \theta} = (-6.84, -1.45)$$




Линейная регрессия

$$y = 2.14x + 0.1$$


Loss = 0.8



$$\frac{\partial L}{\partial \theta} = (-3.6, -0.8)$$




Пример 2. Задача логистической регрессии



Логистическая функция

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$(-\infty; +\infty) \rightarrow (0; 1)$



Пример 2. Задача логистической регрессии

- Вид модели:

$$h(x; \theta) = \sigma(\theta x)$$

- Функция потерь:

$$L(\hat{y}, y) = -\frac{1}{m} \sum_{i=1}^m (y \log \hat{y} + (1 - y) \log(1 - \hat{y}))$$

- Градиент:

$$\frac{\partial}{\partial \theta} L(h(x; \theta), y) = -\frac{1}{m} \sum_{i=1}^m (h(x; \theta) - y)x$$

Разновидности градиентного спуска

- По количеству данных, на которых вычисляется градиент:
 - Один образец – стохастический градиентный спуск, SGD
 - Мини-пакетный (мини-батч) – подмножество фиксированного размера
 - Пакетный (батч) – всё обучающее множество
- По особенностям процедуры:
 - Моменты
 - Adam
 - ...

Метрики

- Отличия функции потерь от метрики
 - Метрика (*более*) *интерпретируема* в терминах конкретной решаемой задачи, в большей степени выражает то, в какой степени *достигается цель* обучения модели
 - Попытка формализации степени достижения *цели*
 - Метрика не обязательно дифференцируема

Метрики. Регрессия

Средняя абсолютная ошибка,
Mean absolute error, MAE


$$MAE = \frac{1}{n} \sum_{i=1}^n |h(x_i) - y_i|$$

i	x	y	$h(x)$
1	2	3	5
2	3	9	7
3	4	14	9
4	5	10	11
5	7	16	15

$$MAE = (2 + 2 + 5 + 1 + 1)/5 = 2.2$$

Среднеквадратичная ошибка,
Root mean squared error, RMSE

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (h(x_i) - y_i)^2}$$



$$RMSE = \sqrt{4 + 4 + 25 + 1 + 1}/5 \approx 2.65$$

Метрики. Классификация

- Доля истинных результатов (Accuracy):

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

- Точность (Precision):

$$P = \frac{TP}{TP + FP}$$

- Полнота (Recall):

$$R = \frac{TP}{TP + FN}$$

- F1:

$$F1 = \frac{2 * P * R}{P + R}$$


Матрица ошибок (матрица неточностей)

		Истинный класс	
		Положительный, Positive	Отрицательный, Negative
Результат модели	Положительный, Positive	Истинно положительные, TP	Ложно положительные, ошибки 1-го рода, FP
	Отрицательный, Negative	Ложно отрицательные, ошибка 2-го рода, FN	Истинно отрицательные, TN

Метрики. Классификация. ROC AUC

Какую долю истинно положительных образцов модель может «вернуть», если ей «разрешить» заданную долю ложно положительных

№	Предсказание	Истинный класс
2	0.9	1
4	0.7	1
7	0.7	0
5	0.6	0
6	0.5	1
3	0.1	0
1	0.0	0



Количество положительных
в наборе

Количество отрицательных
в наборе

Интересные свойства:

- не зависит от порога классификации
- вероятности принадлежности классам не обязаны быть $[0; 1]$, оценивает качество *упорядочивания*

Метрики. Прочие

scikit-learn

Install User Guide API Examples Community More

Prev Up Next

scikit-learn 1.3.1
Other versions

Please cite us if you use the software.

API Reference

sklearn.base: Base classes and utility functions
sklearn.calibration: Probability Calibration
sklearn.cluster: Clustering
sklearn.compose: Composite Estimators
sklearn.covariance: Covariance Estimators
sklearn.cross_decomposition: Cross decomposition
sklearn.datasets: Datasets
sklearn.decomposition: Matrix Decomposition
sklearn.discriminant_analysis: Discriminant Analysis
sklearn.dummy: Dummy estimators
sklearn.ensemble: Ensemble Methods
sklearn.exceptions: Exceptions and warnings
sklearn.experimental: Experimental
sklearn.feature_extraction: Feature Extraction
sklearn.feature_selection: Feature Selection
sklearn.gaussian_process: Gaussian Processes
sklearn.impute: Impute
sklearn.inspection: Inspection
sklearn.isotonic: Isotonic regression
sklearn.kernel_approximation: Kernel Approximation
sklearn.kernel_ridge: Kernel Ridge Regression
sklearn.linear_model: Linear Models
sklearn.manifold: Manifold Learning
sklearn.metrics: Metrics
sklearn.mixture: Gaussian Mixture Models
sklearn.model_selection: Model Selection
sklearn.multiclass: Multiclass classification
sklearn.multioutput: Multioutput regression and classification
sklearn.naive_bayes: Naive Bayes
sklearn.neighbors: Nearest Neighbors
sklearn.neural_network: Neural network models

Classification metrics


See the Classification metrics section of the user guide for further details.

<code>metrics.accuracy_score(y_true, y_pred, *[, ...])</code>	Accuracy classification score.
<code>metrics.auc(x, y)</code>	Compute Area Under the Curve (AUC) using the trapezoidal rule.
<code>metrics.average_precision_score(y_true, ...)</code>	Compute average precision (AP) from prediction scores.
<code>metrics.balanced_accuracy_score(y_true, ...)</code>	Compute the balanced accuracy.
<code>metrics.brier_score_loss(y_true, y_prob, *)</code>	Compute the Brier score loss.
<code>metrics.class_likelihood_ratios(y_true, ...)</code>	Compute binary classification positive and negative likelihood ratios.
<code>metrics.classification_report(y_true, y_pred, *)</code>	Build a text report showing the main classification metrics.
<code>metrics.cohen_kappa_score(y1, y2, *[, ...])</code>	Compute Cohen's kappa: a statistic that measures inter-annotator agreement.
<code>metrics.confusion_matrix(y_true, y_pred, *)</code>	Compute confusion matrix to evaluate the accuracy of a classification.
<code>metrics.dcg_score(y_true, y_score, *[, k, ...])</code>	Compute Discounted Cumulative Gain.
<code>metrics.det_curve(y_true, y_score[, ...])</code>	Compute error rates for different probability thresholds.
<code>metrics.f1_score(y_true, y_pred, *[, ...])</code>	Compute the F1 score, also known as balanced F-score or F-measure.
<code>metrics.fbeta_score(y_true, y_pred, *, beta)</code>	Compute the F-beta score.
<code>metrics.hamming_loss(y_true, y_pred, *[, ...])</code>	Compute the average Hamming loss.
<code>metrics.hinge_loss(y_true, pred_decision, *)</code>	Average hinge loss (non-regularized).
<code>metrics.jaccard_score(y_true, y_pred, *[, ...])</code>	Jaccard similarity coefficient score.
<code>metrics.log_loss(y_true, y_pred, *[, eps, ...])</code>	Log loss, aka logistic loss or cross-entropy loss.
<code>metrics.matthews_corrcoef(y_true, y_pred, *)</code>	Compute the Matthews correlation coefficient (MCC).
<code>metrics.multilabel_confusion_matrix(y_true, ...)</code>	Compute a confusion matrix for each class or sample.
<code>metrics.ndcg_score(y_true, y_score, *[, k, ...])</code>	Compute Normalized Discounted Cumulative Gain.
<code>metrics.precision_recall_curve(y_true, ...)</code>	Compute precision-recall pairs for different probability thresholds.
<code>metrics.precision_recall_fscore_support(...)</code>	Compute precision, recall, F-measure and support for each class.
<code>metrics.precision_score(y_true, y_pred, *[, ...])</code>	Compute the precision.
<code>metrics.recall_score(y_true, y_pred, *[, ...])</code>	Compute the recall.
<code>metrics.roc_auc_score(y_true, y_score, *[, ...])</code>	Compute Area Under the Receiver Operating Characteristic Curve (ROC AUC) from prediction scores.
<code>metrics.roc_curve(y_true, y_score, *[, ...])</code>	Compute Receiver operating characteristic (ROC).
<code>metrics.top_k_accuracy_score(y_true, y_score, *)</code>	Top-k Accuracy classification score.
<code>metrics.zero_one_loss(y_true, y_pred, *[, ...])</code>	Zero-one classification loss.


Regression metrics

See the Regression metrics section of the user guide for further details.


<code>metrics.explained_variance_score(y_true, ...)</code>	Explained variance regression score function.
<code>metrics.max_error(y_true, y_pred)</code>	The max_error metric calculates the maximum residual error.
<code>metrics.mean_absolute_error(y_true, y_pred, *)</code>	Mean absolute error regression loss.
<code>metrics.mean_squared_error(y_true, y_pred, *)</code>	Mean squared error regression loss.
<code>metrics.mean_squared_log_error(y_true, y_pred, *)</code>	Mean squared logarithmic error regression loss.
<code>metrics.median_absolute_error(y_true, y_pred, *)</code>	Median absolute error regression loss.
<code>metrics.mean_absolute_percentage_error(...)</code>	Mean absolute percentage error (MAPE) regression loss.
<code>metrics.r2_score(y_true, y_pred, *[, ...])</code>	R^2 (coefficient of determination) regression score function.
<code>metrics.mean_poisson_deviance(y_true, y_pred, *)</code>	Mean Poisson deviance regression loss.
<code>metrics.mean_gamma_deviance(y_true, y_pred, *)</code>	Mean Gamma deviance regression loss.
<code>metrics.mean_tweedie_deviance(y_true, y_pred, *)</code>	Mean Tweedie deviance regression loss.
<code>metrics.d2_tweedie_score(y_true, y_pred, *)</code>	D^2 regression score function, fraction of Tweedie deviance explained.
<code>metrics.mean_pinball_loss(y_true, y_pred, *)</code>	Pinball loss for quantile regression.
<code>metrics.d2_pinball_score(y_true, y_pred, *)</code>	D^2 regression score function, fraction of pinball loss explained.
<code>metrics.d2_absolute_error_score(y_true, ...)</code>	D^2 regression score function, fraction of absolute error explained.



$$IOU = \frac{\text{area of overlap}}{\text{area of union}} =$$



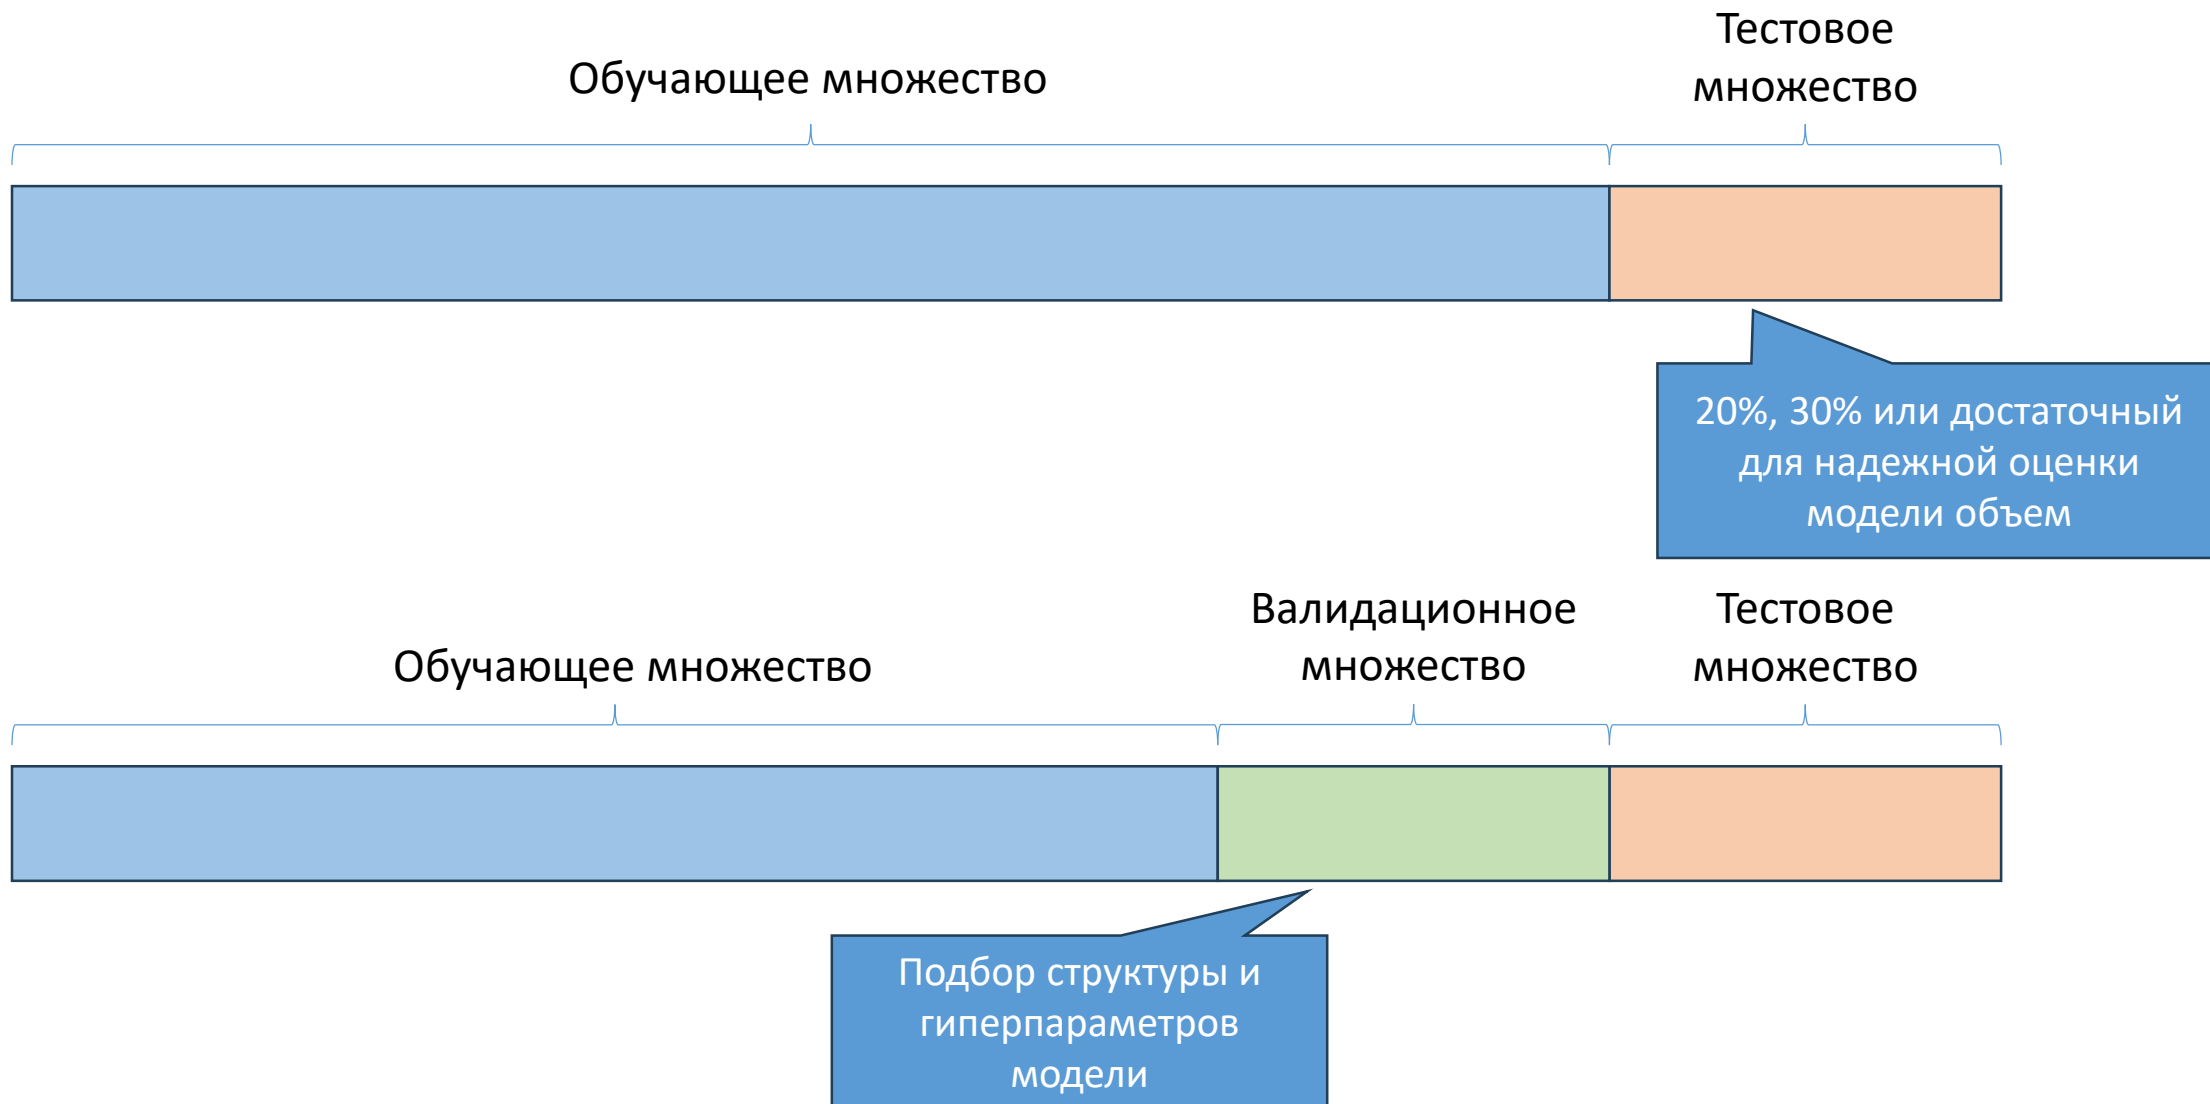
$$DICE =$$



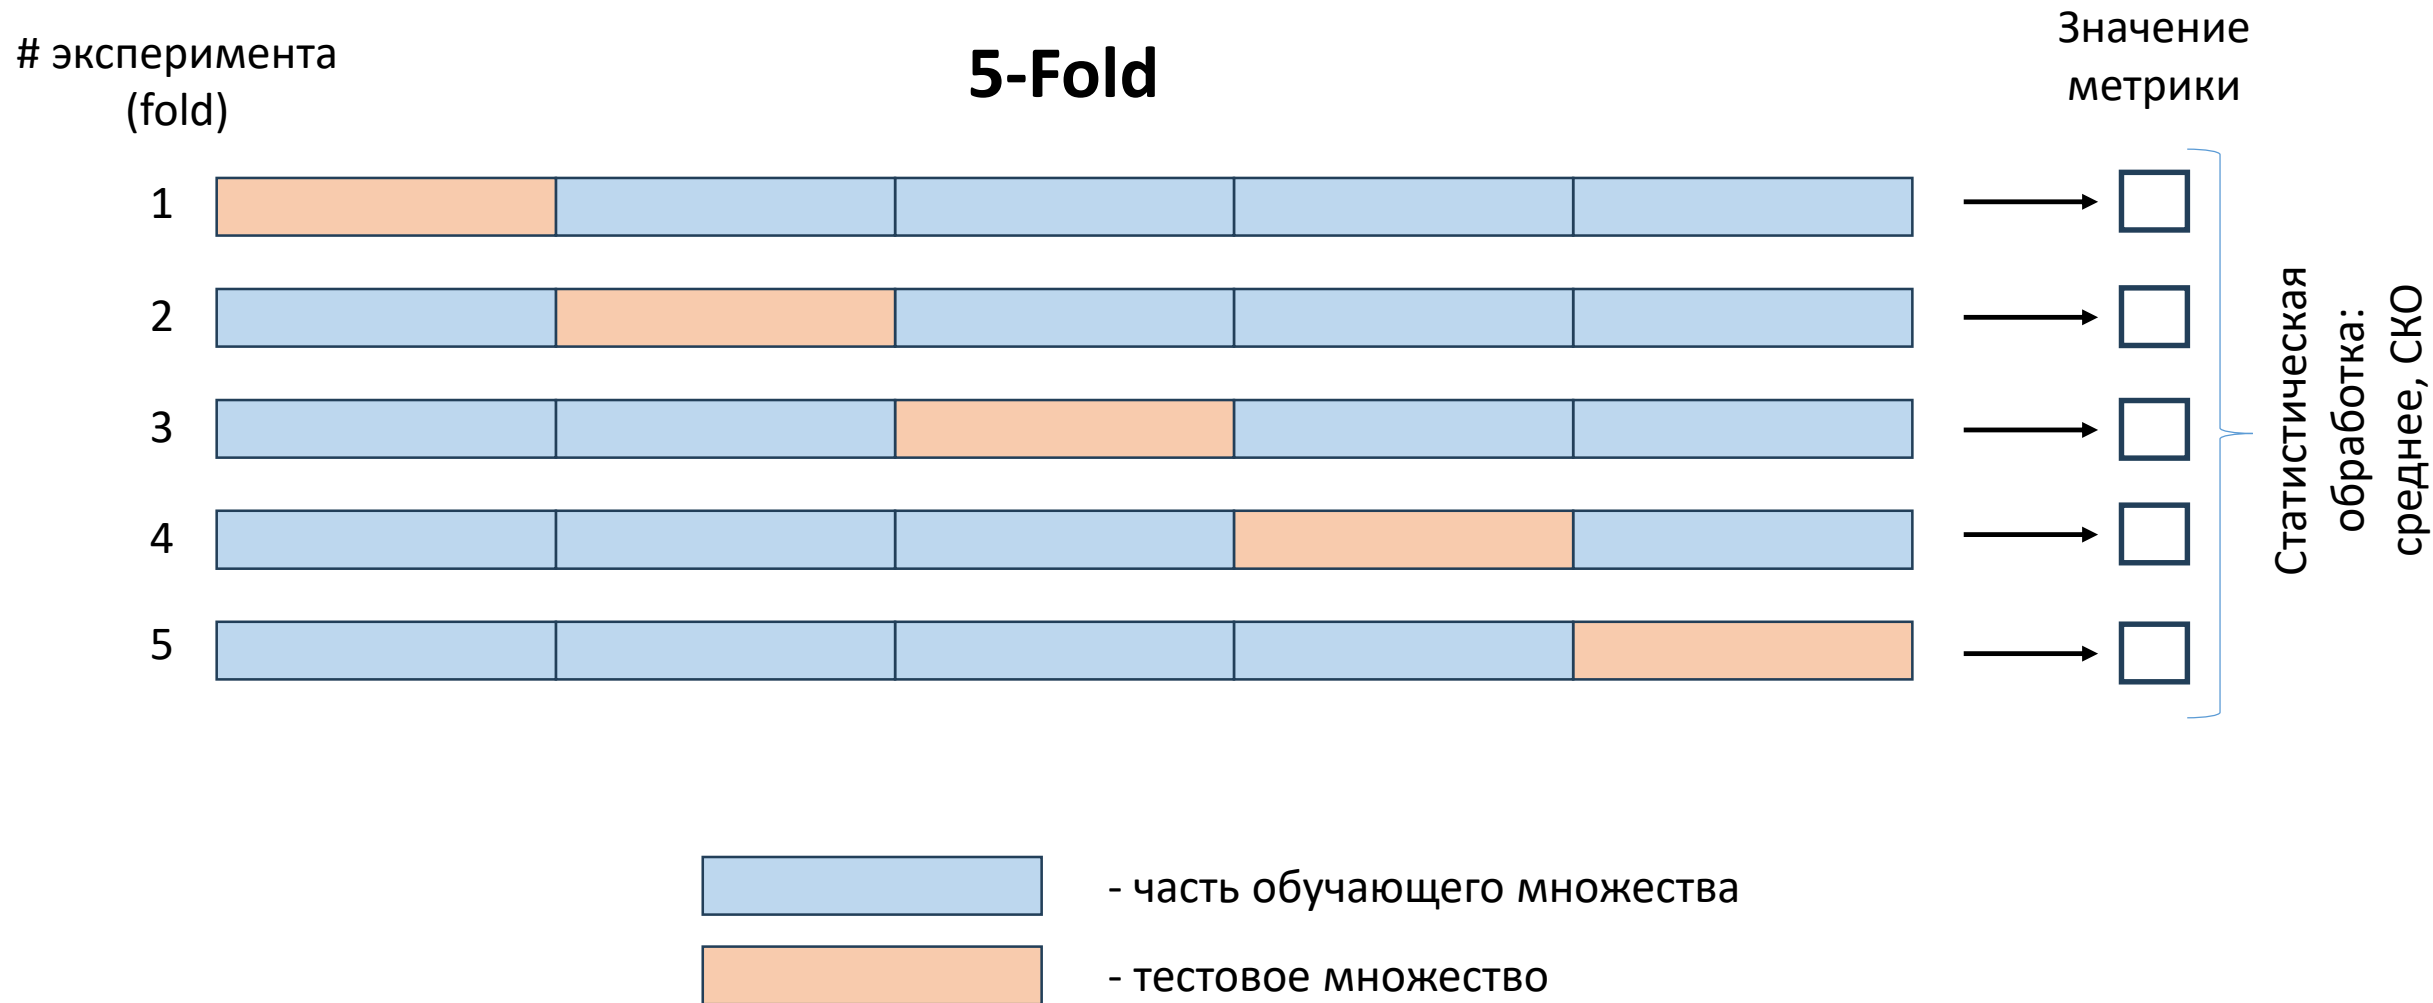
Валидация

- Валидация – проверка характеристик модели, оценка в какой степени модель удовлетворяет требованиям
 - В частности, на тех данных, которые не были использованы при обучении
- Основные схемы валидации:
 - Отложенная выборка
 - Обучающая и тестовая выборки
 - Обучающая, валидационная и тестовая выборки
 - Перекрестная валидация (K-Fold)

Валидация. Отложенные выборки



Валидация. Перекрестная валидация (кросс-валидация)



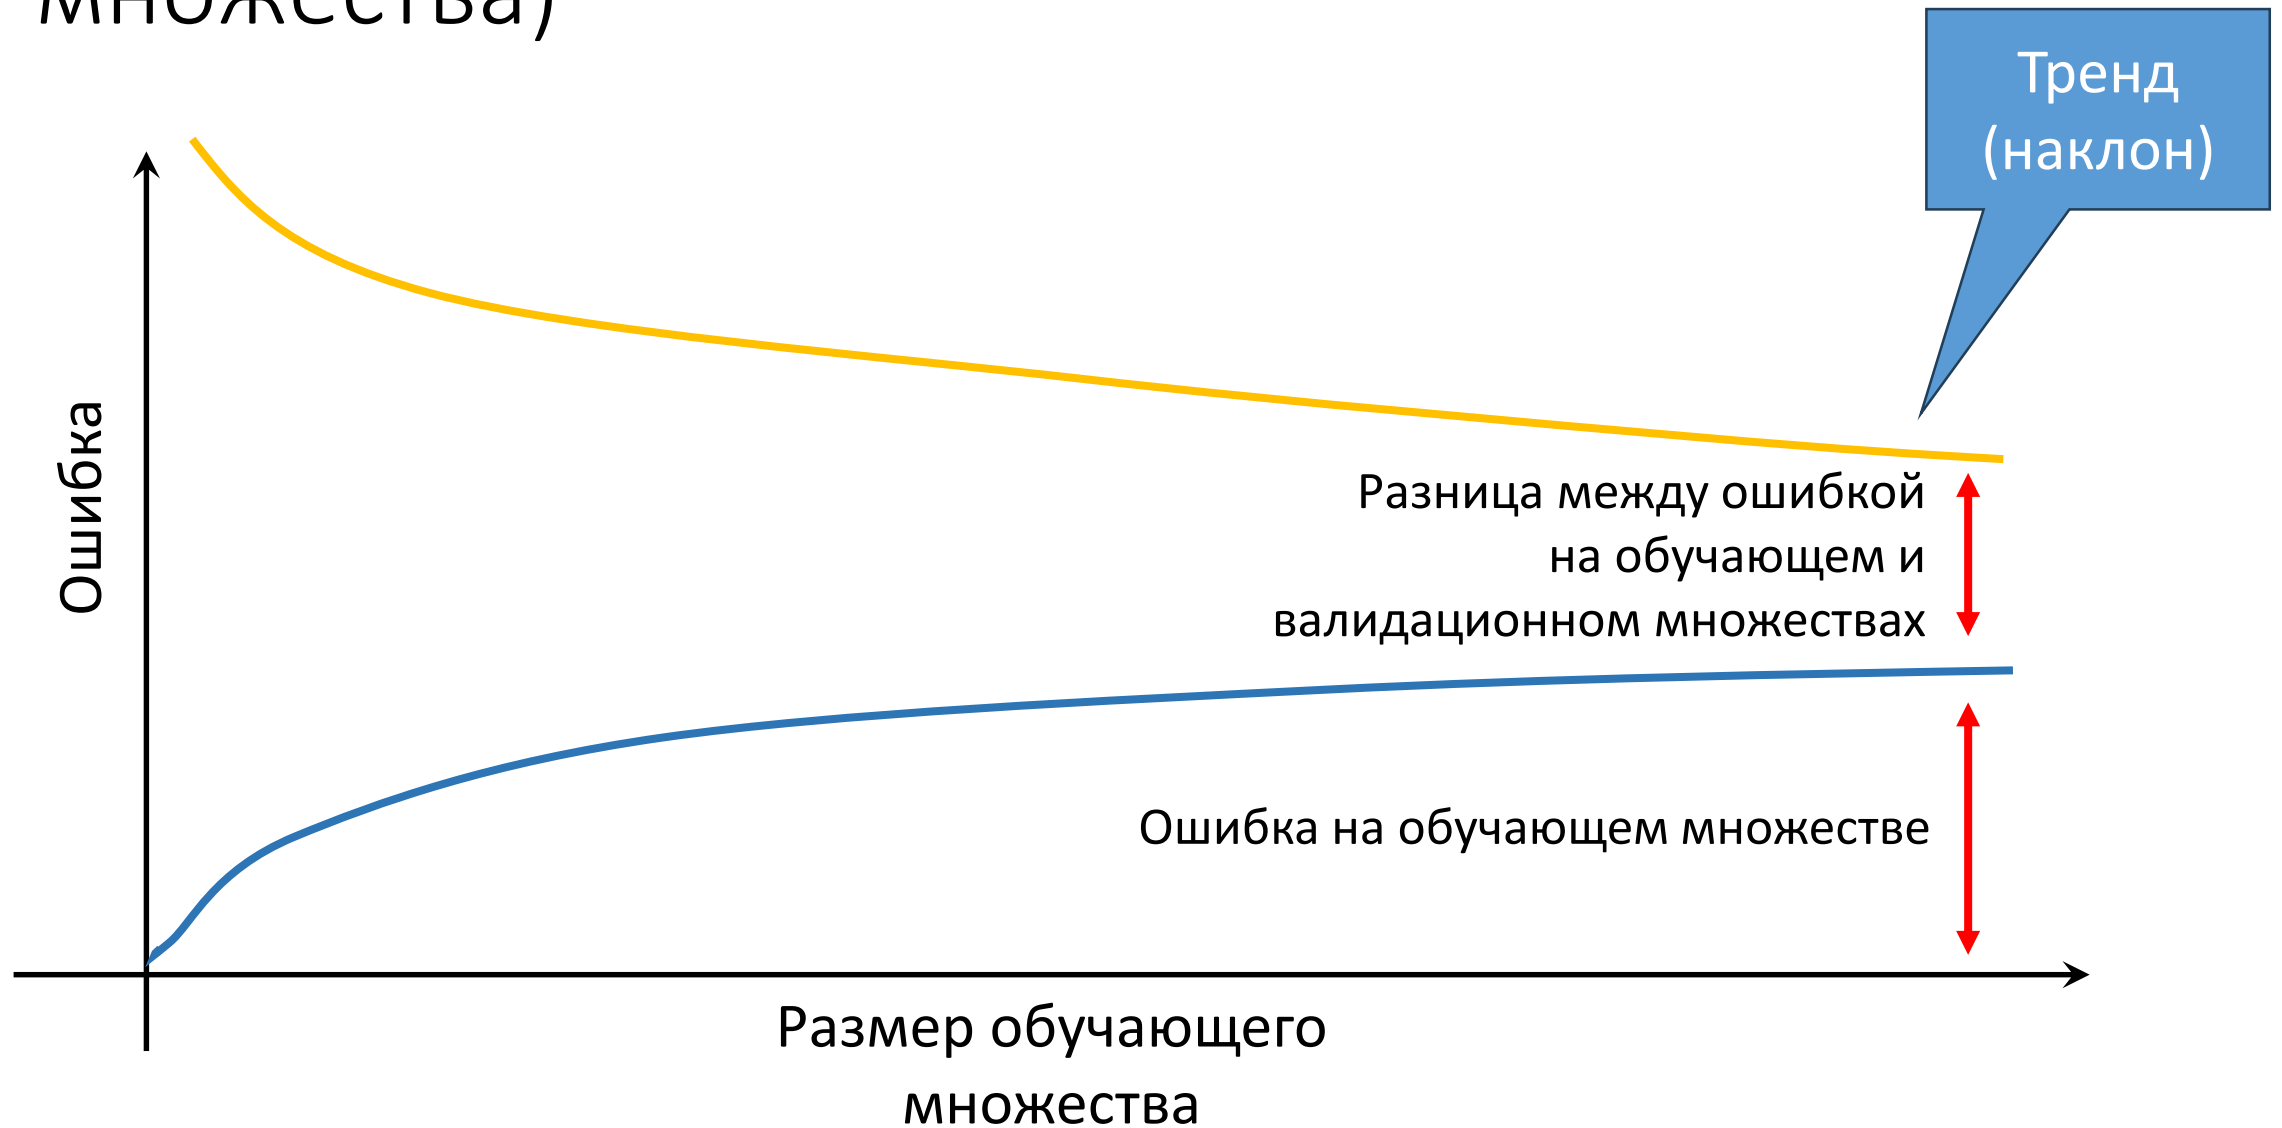
Валидация. Важные аспекты разбиения

- Соответствие тестовой выборки целевому использованию модели
- Достаточный размер
- Отсутствие «утечек» в тестовую выборку
 - Тот же пациент
 - Тот же период (во временных моделях)
- Нужна ли группировка?
- Нужна ли стратификация?



Диагностика моделей. Кривые обучения

- Два вида:
 - От размера обучающего множества
 - От количества итераций обучения

Кривые обучения (от размера обучающего множества)




Кривые обучения (от размера обучающего множества)




Кривые обучения (от количества итераций)


ОК



Недообученная модель
(продолжить обучение)

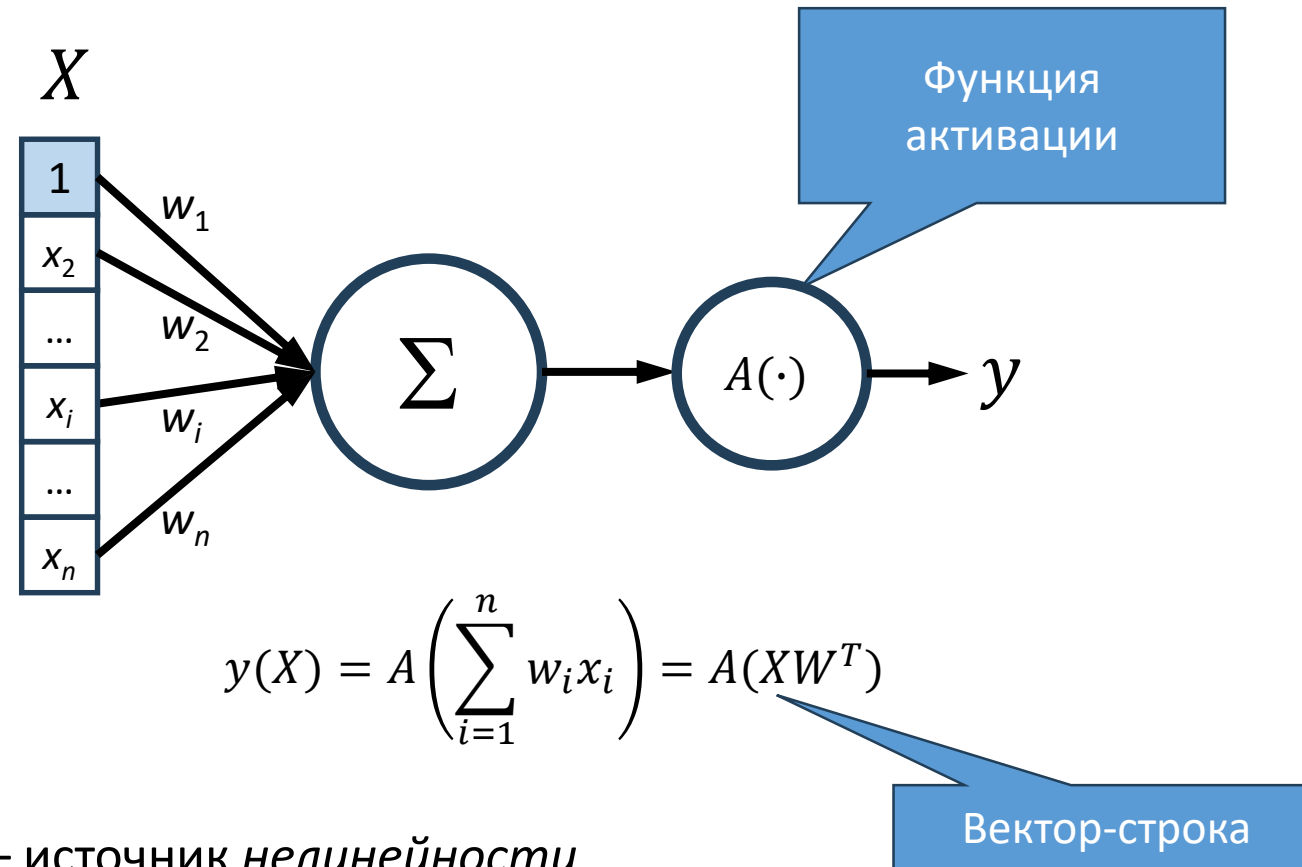


**Переобученная модель,
оверфиттинг,**
(ранний останов,
увеличить размер
обучающего множества,
упростить модель)



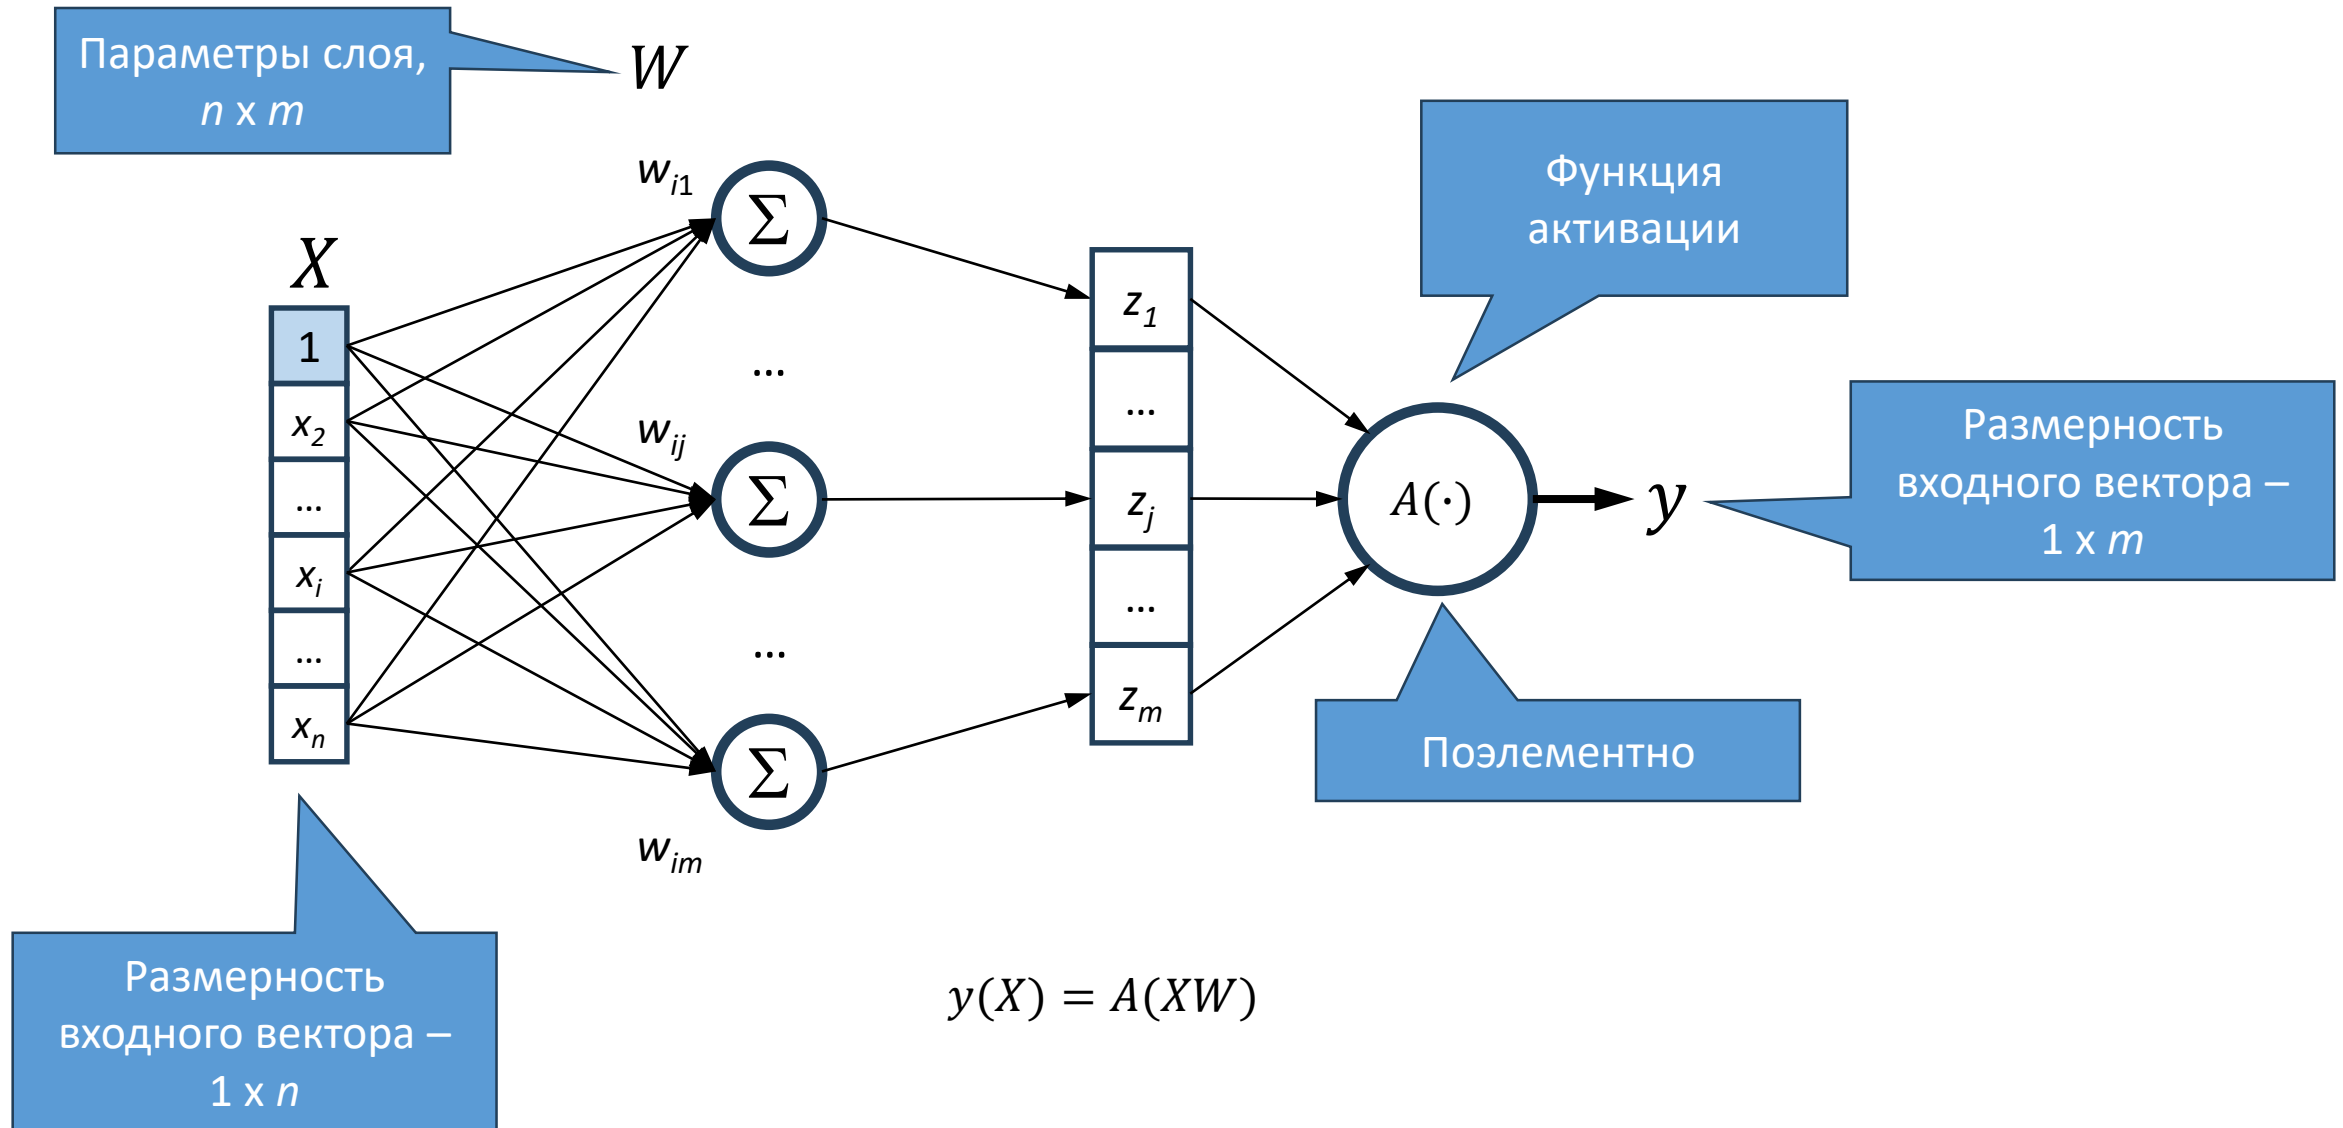
Тема 10. Обучение нейронных сетей

Модель одного искусственного нейрона

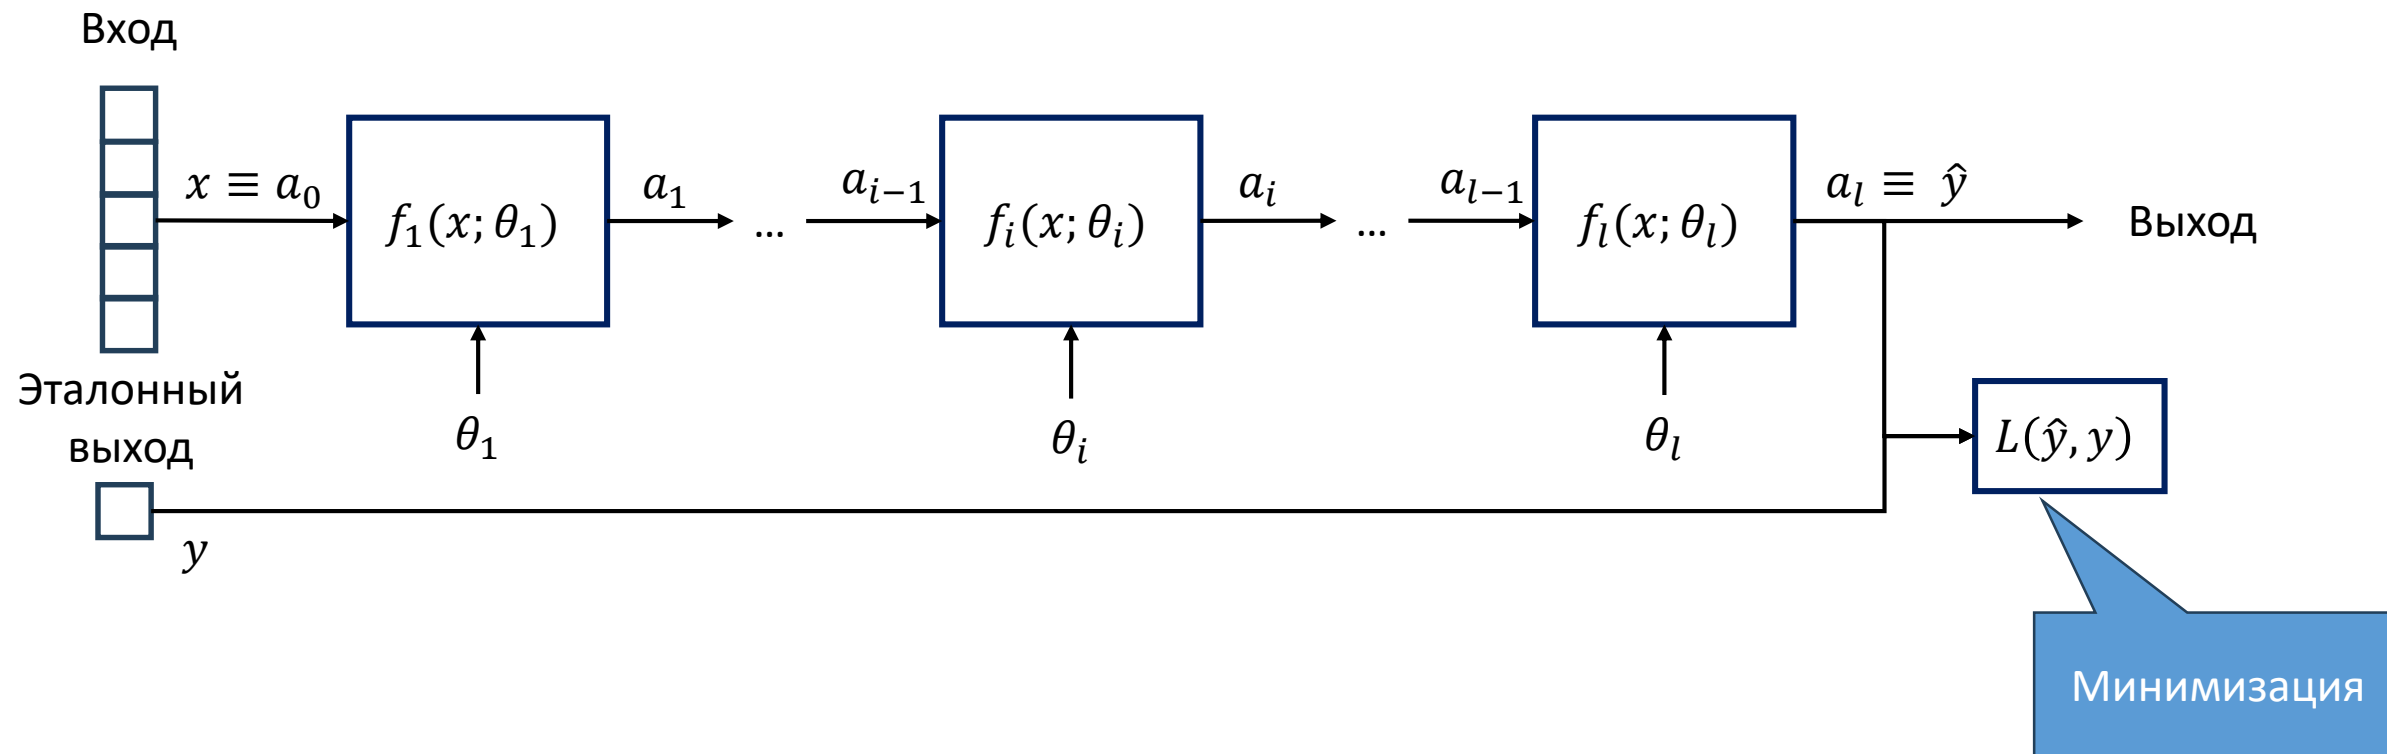


- Функция активации – источник *нелинейности*
- Без $A(\cdot)$ – линейная регрессия
- При $A(x) \equiv \sigma(x) \equiv (1 + e^{-x})^{-1}$ – логистическая регрессия (только линейная разделимость)

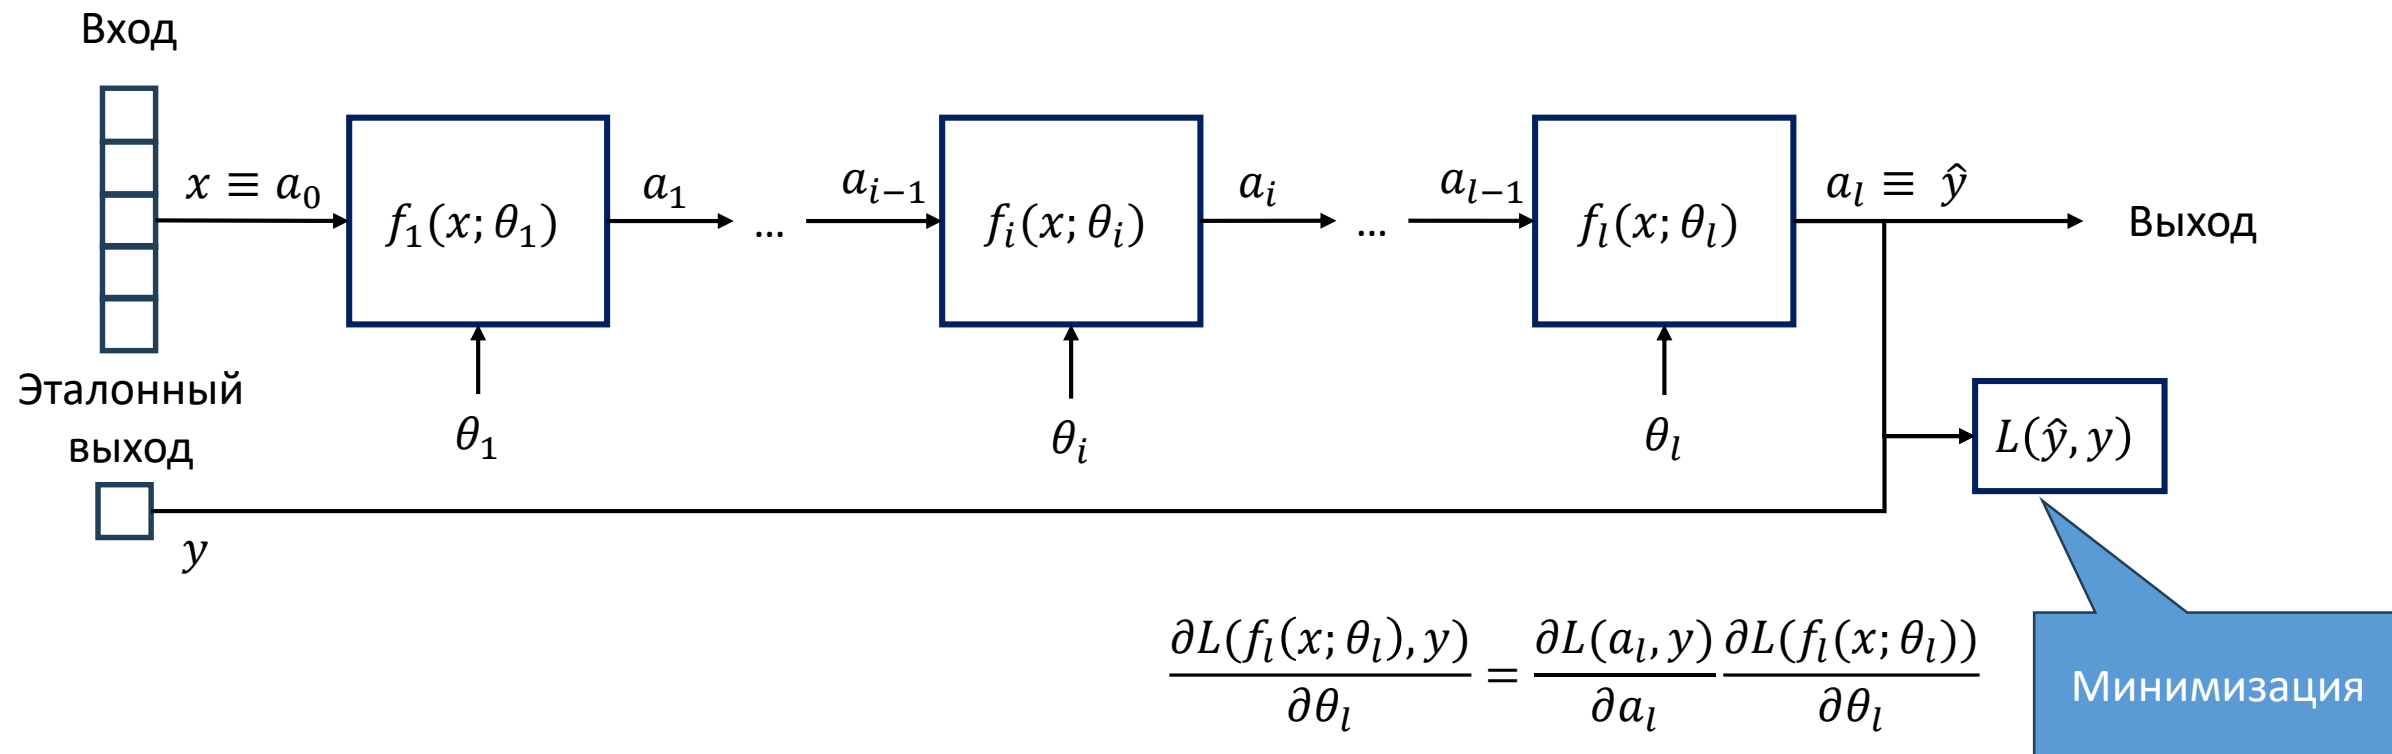
Слой искусственных нейронов



Нейронная сеть



Нейронная сеть




Функции активации


Внутри сети (скрытые слои)

$$a(x) = \max(x, 0)$$

См. также:
Leaky ReLU, ELU и др.




$$a(x) = \tanh(x)$$



Последний слой

Сигмоидальная
(бинарная классификация)

$$a(x) = \frac{1}{1 + e^{-x}}$$




Softmax (многоклассовая классификация)

$$\begin{pmatrix} 2 \\ -1 \\ 3 \end{pmatrix} \rightarrow \frac{e^{x_i}}{\sum_j e^{x_j}} \rightarrow \begin{pmatrix} 0.27 \\ 0.01 \\ 0.72 \end{pmatrix}$$

Сложность и выразительность сети

- «Выразительность» сети:
 - Количество слоев
 - Количество нейронов в слое
- Теоретически:
 - Достаточно одного скрытого слоя
- На практике:
 - Можно обойтись меньшим количеством нейронов, если использовать больше слоёв
 - Но: при очень глубоких сетях (>10) возможны проблемы
 - Возможные решения: residual networks, skip connections



Регуляризация. Исключение/дропаут (Dropout)

- Цель регуляризации:
 - Уменьшение переобучения

- Весовая регуляризация:
 - Наложение штрафа на величину весов сети:

$$L_r(x, y; \theta) = L(x, y; \theta) + \gamma R(\theta)$$

$\|\theta\|_1$ -
абсолютные
значения

$\|\theta\|_2^2$ - сумма
квадратов

- Исключение/дропаут:
 - Предотвращение образования сильных связей между нейронами в соседних слоях посредством выбрасывания (зануления) выходов слоя с определенной вероятностью
 - Режим обучения и режим «вывода» (предсказания)

Пакетная нормализация (batch normalization)

- Идея:
 - масштабирование данных, приведение их в «удобный» диапазон

Вход: Пакет $B = \{x_1, \dots, x_m\}$, параметры γ, β , константа ϵ .

Выход: $\{y_1, \dots, y_m\}$

$$\mu_B = \frac{1}{m} \sum_{i=1}^m x_i$$

$$\sigma_B^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \mu_B)^2$$

$$\hat{x}_i = (x_i - \mu_B) / \sqrt{\sigma_B^2 + \epsilon}$$

$$y_i = \gamma \hat{x}_i + \beta$$



Обучаются

Пакетная нормализация (batch normalization)

- Полезные свойства:
 - достигается более быстрая сходимость моделей, несмотря на выполнение дополнительных вычислений;
 - пакетная нормализация позволяет каждому слою сети обучаться более независимо от других слоев;
 - становится возможным использование более высокого темпа обучения, так как пакетная нормализация гарантирует, что выходы узлов нейронной сети не будут иметь слишком больших или малых значений;
 - пакетная нормализация в каком-то смысле также является механизмом регуляризации: данный метод привносит в выходы узлов скрытых слоев некоторый шум, аналогично методу dropout;
 - модели становятся менее чувствительны к начальной инициализации весов.

Литература

- Основное:
 - Рассел С., Норвиг П. Искусственный интеллект. Современный подход. 4-е издание
- Дополнительно:
 - Dive into Deep Learning: <http://d2l.ai>
 - Coursera/DeepLearning.AI: Deep Learning Specialization (Andrew Ng)
 - Блог А. Дьяконова: <https://alexanderdyakonov.wordpress.com>
 - ROC AUC и вообще много хороших материалов:
 - <https://alexanderdyakonov.wordpress.com/2017/07/28/auc-roc-площадь-под-кривой-ошибок/>